

약물 리뷰 기반 부작용 위험 탐지

환자 리뷰 텍스트에 **평점·약물 통계 특성**을 더해 **심각한 부작용(ADE) 위험 신호**를
골라내는 Streamlit 서비스

장진석 · 20241499

빅데이터 분석 프로젝트 · 기말 프로젝트

문제정의 & 데이터

- ▶ 풀려는 문제 : 환자 리뷰·평점에서 **심각한 부작용(ADE)**
위험 신호 조기 탐지 (먹기 전·후 참고)


라이선스: UCI **CC BY 4.0** / Kaggle **CC BY-NC-SA 4.0** → 엄격한 쪽 준수, 출처만 명시

```
데이터 출처 : kaggle cache: drugsComTrain_raw.csv
행 x 열      : 161,297 x 7
컬럼        : ['review_id', 'drug_name', 'condition', 'review', 'rating', 'date', 'useful_count']
형식        : CSV (표 형태)

[ 컬럼별 자료형(dtype) ]
review_id      int64
drug_name      object
condition      object
review         object
rating         int64
date           datetime64[ns]
useful_count   int64
dtype: object
```


UCI Drug Review (Kaggle) · **215,063행 × 7열 · CSV**
위험군/안전군 이진 분류 (**18.6%**) — 정답 없어 **약한 라벨링**

EDA · 시각화 발견



평점은 J자형 (10·1점 양극단)

→ 위험군 평점 중앙값 2 vs 안전군 9 — "낮은 평점 = 불만 신호"



상관 히트맵 — 누수 단서

→ severe 키워드 ↔ 라벨 **0.64**. 라벨을 그 키워드로 만들어서(=정답 베끼기) → 학습에서 제외 (→슬5)

그 외: 약물 **3,671종** (약물별 IQR 기준 필요) · condition **HTML 잔여물** → 전처리

▶ 라이브 데모 — 실제 앱으로 전환


① 모델 서비스 — 약물 Sertraline · 증상 chest pain...
could not breathe · 평점 2

위험도 ~75% · 심각한 부작용 위험군


※ 위험군 = '확정'이 아니라 주의 깊게 볼 리뷰를 골라낸 선별 신호

▶ 약물별 IQR 이상치 판정 + 과거 유사 리뷰 + 상담 리포트

② AI 챗봇 — 약물 선택 → 그 약물 리뷰 근거(grounding)로 부작용 질의응답



① 예측 결과 화면



② 약물 근거 LLM 챗봇 — 시연 실패 시 이 두 캡처가 백업

★ 모델 · 특성 · 성능 — "정직한 숫자"


▶ RandomForest 배포

처음 99.6% / AUC 1.0 → 타킷 누수 (라벨 정의 컬럼이 학습에 포함)
제외 후 재학습 = 정직한 F1 0.90

모델	F1	AUC
RandomForest (배포)	90.2%	0.983
단순규칙 (rating≤3)	61.9%	—

컬럼	구분	dtype
review_id	원본 (raw)	int64
drug_name	원본 (raw)	object
condition	원본 (raw)	object
review	원본 (raw)	object
rating	원본 (raw)	int64
date	원본 (raw)	datetime64[ns]
useful_count	원본 (raw)	int64
review_length	새 특성 (학습)	int64
word_count	새 특성 (학습)	int64
exclamation_count	새 특성 (학습)	int64
uppercase_ratio	새 특성 (학습)	float64
severe_keyword_count	라벨정의 → 학습 제외	int64
symptom_keyword_count	라벨정의 → 학습 제외	int64
positive_keyword_count	새 특성 (학습)	int64
low_rating_flag	라벨정의 → 학습 제외	int64
risk_label	target	int64
drug_review_count	새 특성 (학습)	int64
drug_avg_rating	새 특성 (학습)	float64


(원본 7컬럼 → 도출): IQR 이상치·리뷰 길이·느낌표·긍정어 등 — 전부 EDA 근거 + TF-IDF 1,500



→ 상위: rating·hospital·er·suicidal 등 의미 토큰 (단순규칙 F1 0.62 증가)

결론 · 한계

결론 — 리뷰 텍스트 + 평점·통계로 위험군을 **정직한 F1 0.90**으로 분류. (아래 **단일 진실 원천** 구조로 R&D ↔ 앱이 같은 코드.)



- ▶ **한계** 데이터·키워드·TF-IDF 모두 영어 기반 → **한국어 리뷰엔 그대로 적용 불가** (ML·LLM 공통)
- ▶ **향후** 한국어 리뷰 데이터 확보 · 한국어 키워드 사전 구축 · 한국 의약품 자료로 확장

감사합니다